Analyse de données avec Python

Enseignant :	Louis RAYNAL	**Établissement :**	ICES
Contact :	l-raynal@ices.fr	**Année :**	2023-2024
Public :	L1 Maths		
Ressources :	https://github.com/LouisRaynal/pythonData		

Examen du 22/04/2024 (3 heures)

Documents autorisés : Tous les documents utilisés lors des TP (polycopiés annotés, corrections, scripts Python personnels), notes personnelles (fiches mémo, sommaires,...), et ressources disponibles à l'adresse https://github.com/LouisRaynal/pythonData.

Rappels : Toute forme de communication entre vous est interdite. Tricher peut engendrer une interdiction de participer à tout examen pendant 5 ans.

Important : À la fin de l'examen il vous faudra envoyer votre script Python à l'adresse l-raynal@ices.fr.

Mémos pour Mac :

{ = Alt + (} = Alt +) | = Alt + ⇧ + L
[= Alt + ⇧ + ( ] = Alt + ⇧ +)

Au cas où vous avez un problème avec les fenêtres de Spyder :
View > Window Layouts > Spyder Default Layout

Pratique

Ouvrir le navigateur Anaconda (*Anaconda-navigator*), puis Spyder.

Ouvrir un nouveau fichier *.py* dans Spyder, que vous sauvegarderez sur votre bureau avec le nom *Examen1_nom_prénom.py*. Vous répondrez aux questions dans ce fichier.

Ajouter en début du fichier votre nom et prénom en commentaire, puis les lignes d'import des librairies que vous pourriez être amenées à utiliser lors de cet examen, soit :

```
# Votre nom et prénom ici

import os
import numpy as np
import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt
import scipy.stats as ss
```

Ajouter également cette ligne qui vous permettra d'afficher toutes les colonnes des DataFrames pandas.

```
pd.options.display.max_columns = None
```

Exécuter ces codes.

Pour cet examen, avant de répondre à chaque question, veillez à écrire le numéro de la question en commentaire. Par exemple :

```
# Question X
```

Pour les questions nécessitant de commenter des résultats, le faire dans votre fichier Python, dans des lignes de commentaires.

Pour les questions nécessitant de vérifier ou calculer quelque chose, le faire dans votre fichier Python grâce à une ou plusieurs lignes de code.

Présentation du jeu de données

Le jeu de données que vous allez analyser concerne 301 voitures d'occasion mises en vente.

Pour chaque voiture mise en vente, les informations suivantes sont recueillies :

- `Car_Name` - le modèle de la voiture ;
- `Year` - l'année d'acquisition de la voiture ;
- `Selling_Price` - le prix de vente de la voiture en milliers de dollars ;
- `Present_Price` - le prix neuf de la voiture en milliers de dollars ;
- `Kms_Driven` - le nombre de kilomètres au compteur de la voiture ;
- `Fuel_Type` - le type de carburant avec les modalités `Petrol` (essense), `Diesel`, `CNG` (gaz naturel) ;
- `Seller_Type` - le type de vendeur, soit `Dealer` (concessionnaire) soit `Individual` (particulier) ;
- `Transmission` - le type de transmission avec les modalités `Automatic` ou `Manual` ;
- `Owner` - le nombre de propriétaires précédents (sans compter le propriétaire actuel qui vend la voiture).

Questions

1. Les données se trouvent dans le fichier *voitures.csv*, à l'adresse `https://github.com/LouisRaynal/pythonData/tree/main/Examen1`.
   Rendez-vous à cette adresse avec le navigateur web **Google chrome** et sauvegardez ce fichier de la manière suivante :
   - clic gauche sur le nom du fichier *voitures.csv*
   - faire ensuite un clic gauche sur le bouton Raw
   - faire un **clic droit** puis ***Enregistrer sous...***, et sauvegarder le fichier sur votre bureau avec le nom *voitures.csv* (ajouter si besoin l'extension .csv si elle n'est pas présente)
2. Chargez dans Spyder le fichier *voitures.csv* afin d'obtenir un DataFrame `pandas` que vous stockerez dans une variable nommée `df`. Prendre en compte dans votre import les trois points suivants :
   - la première ligne du fichier contient le nom de vos variables
   - toutes les lignes sont à importer
   - le séparateur de données utilisé est la virgule

   Vérifiez ensuite avec une ligne de code Python que votre DataFrame `df` contient bien 301 lignes (hors entête) et 9 colonnes.
3. Renommez chacune des 9 colonnes avec le nom de votre choix, puis vérifiez que le changement a bien été effectif en affichant le nom des colonnes de `df`.
4. Vérifiez s'il existe des lignes qui apparaissent en plusieurs exemplaires. Si c'est le cas, supprimez les doublons de `df`, puis vérifiez que cette suppression a bien fonctionné.
5. Ce jeu de données contient des valeurs manquantes dans les colonnes initialement nommées `Selling_Price` et `Owner`.
   (a) Comptez combien il y a de valeurs manquantes dans chaque colonne de `df`.
   (b) Pour la colonne `Selling_Price`, remplacez les valeurs manquantes par la valeur médiane du prix de vente. Pour la colonne `Owner`, remplacez les valeurs manquantes par la valeur qui indique que le propriétaire actuel est le premier propriétaire.
   (c) Vérifiez que vous n'avez plus de valeurs manquantes.
6. Une erreur de saisie s'est glissée dans le type de vendeur pour la voiture dont le moèle est `TVS Jupyter`.
   (a) Affichez la ligne concernée par cette erreur. Quelle est la valeur indiquée pour le type de vendeur de cette voiture ?
   (b) Remplacer cette valeur erronée par la valeur `Individual`.
   (c) Vérifiez que votre modification a bien été prise en compte.
7. Le prix de vente de la voiture devrait être inférieur à son prix neuf. Vérifiez cela en comptant combien de lignes ne vérifient pas cette condition.
8. Combien de voitures acquises en 2010 sont en vente ?
9. Quelle est la proportion de voitures acquises en 2015 ?
10. Combien de voitures diesel acquises en 2014 sont en vente ?
11. Calculez en fréquences les distributions du type de carburant, conditionnellement aux modalités de la variable `Transmission`. Calculez également la distribution marginale du type de carburant en fréquences. Étant données ces distributions, est-ce que le type de carburant et le type de transmission semblent indépendants ? (Justifiez votre réponse)

12. Réalisez un test d'indépendance du χ^2 entre les variables type de carburant et type de transmission. D'après ce test, les deux variables sont-elles indépendantes ?

13. Quel est le prix minimal, maximal, moyen et médian de vente des voitures ? Représentez ensuite la distribution des prix de vente grâce à un histogramme en densité de fréquence avec 35 classes. Commentez ce graphique.

14. Calculez un intervalle de valeurs de prix de vente, de sorte qu'environ 50% des prix soient contenus dans cet intervalle. Calculez ensuite le pourcentage exact de prix contenus dans cet intervalle. (On rappelle qu'en Python l'opérateur logique "et" s'écrit `&`).

15. Quels sont les modèles de voiture dont le prix de vente est exactement 1000$ plus faible que le prix neuf ?

16. Représentez des boites à moustaches permettant d'illustrer la distribution du prix de vente selon les modalités du type de transmission. Commentez ce graphique.

17. Calculez le coefficient de détermination afin d'évaluer l'impact de la variable initialement nommée `Transmission` sur le prix de vente. Interprétez la valeur trouvée.

18. `df.corr()` permet de calculer toutes les corrélations entre paires de variables numériques de `df`. Le résultat est aussi un DataFrame. Extraire de ce DataFrame (en une seule ligne de code Python), les deux variables les plus corrélées positivement avec la variable prix de vente (en dehors de la variable prix de vente elle-même).

19. Tracez un graphique illustrant le lien qui existe entre le prix de vente et le prix neuf de la voiture. Commentez ce graphique.

20. Étant donnée la forte corrélation linéaire qui existe entre le prix de vente et le prix neuf, nous voulons ajuster un modèle de régression linéaire de telle sorte à pouvoir prédire le prix neuf d'une voiture étant donné son prix de vente d'occasion.
    (a) Ajustez un tel modèle de régression linéaire.
    (b) Représentez le nuage de points entre le prix de vente d'occasion et le prix neuf, ainsi que la droite de régression ajustée.
    (c) Selon le modèle que vous avez ajusté, quel serait le prix neuf d'une voiture vendue d'occasion à 30000$?

21. Nous voulons ici voir si l'année d'acquisition a un impact sur le prix de vente.
    (a) Créez les groupes d'années d'acquisition suivants :
    $]2000; 2005]$, $]2005; 2010]$, $]2010; 2015]$, $]2015; 2020]$.
    (b) Calculez la moyenne, la médiane et l'écart-type des prix de vente pour chaque groupe d'années d'acquisition. Commentez l'évolution du prix médian selon les groupes.

22. Créez une nouvelle colonne dans `df` nommée `premierProp` qui prend la valeur `Oui` si le vendeur actuel est le premier propriétaire de la voiture, et `Non` sinon. Calculez ensuite le prix de vente moyen par modalité de cette nouvelle colonne. Les voitures ayant eu un seul propriétaire sont-elles vendues en moyenne plus cher que les voitures ayant eu plus d'un propriétaire ?

Important : Lorsque vous avez terminé, envoyez votre script Python à l'adresse l-raynal@ices.fr.
(Envoyer votre fichier *Examen1_nom_prénom.py*, ou bien copier-coller tout votre code dans le corps du mail, ou les deux !)