Analyse de données avec Python

| | | | |
|---|---|---|---|
| **Enseignant :** | Louis RAYNAL | **Établissement :** | ICES |
| **Contact :** | l-raynal@ices.fr | **Année :** | 2023-2024 |
| **Public :** | L1 Maths | | |
| **Ressources :** | https://github.com/LouisRaynal/pythonData | | |

# TP 1 : Introduction

**Mémos pour Mac :**

`{` = Alt + ( `}` = Alt + ) `|` = Alt + ⇧ + L
`[` = Alt + ⇧ + ( `]` = Alt + ⇧ + )

Selon la version du clavier Alt peut être à remplacer par Option

**Au cas où vous avez un problème avec les fenêtres de Spyder :**
View > Window Layouts > Spyder Default Layout

Lors de ce TP d'introduction, vous découvrirez l'interface que nous utiliserons pour programmer en Python. Vous (re)verrez des structures qu'il est essentiel de savoir créer et manipuler pour pouvoir analyser des données.

## 1. Outils du cours

### 1.1. Distribution de Python : Anaconda

Nous utiliserons **Anaconda**, qui est une distribution de Python : c'est-à-dire qu'en installant Anaconda, vous installerez également la dernière version de Python (Python 3), ses librairies les plus courantes, ainsi que d'autres outils/logiciels utiles à l'analyse de données.

Anaconda devrait déjà être installé sur les postes de l'ICES.
Pour son installation sur vos ordinateurs personnels, vous pouvez vous rendre à l'adresse :
https://www.anaconda.com/products/distribution

**Pratique**

> Ouvrir le navigateur Anaconda (*Anaconda-Navigator*) sur vos postes.

## 1.2. Spyder

Anaconda contient de nombreux outils pour la programmation Python, notamment des interfaces de développement telles que Spyder et Jupyter notebook. Pour ces TP nous utiliserons l'interface **Spyder**.

### Pratique

Lancer Spyder depuis le navigateur Anaconda.

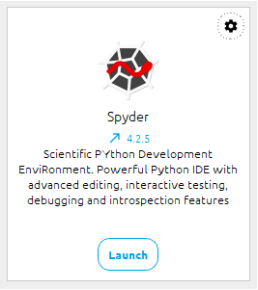


L'espace de travail se présente de la manière suivante :

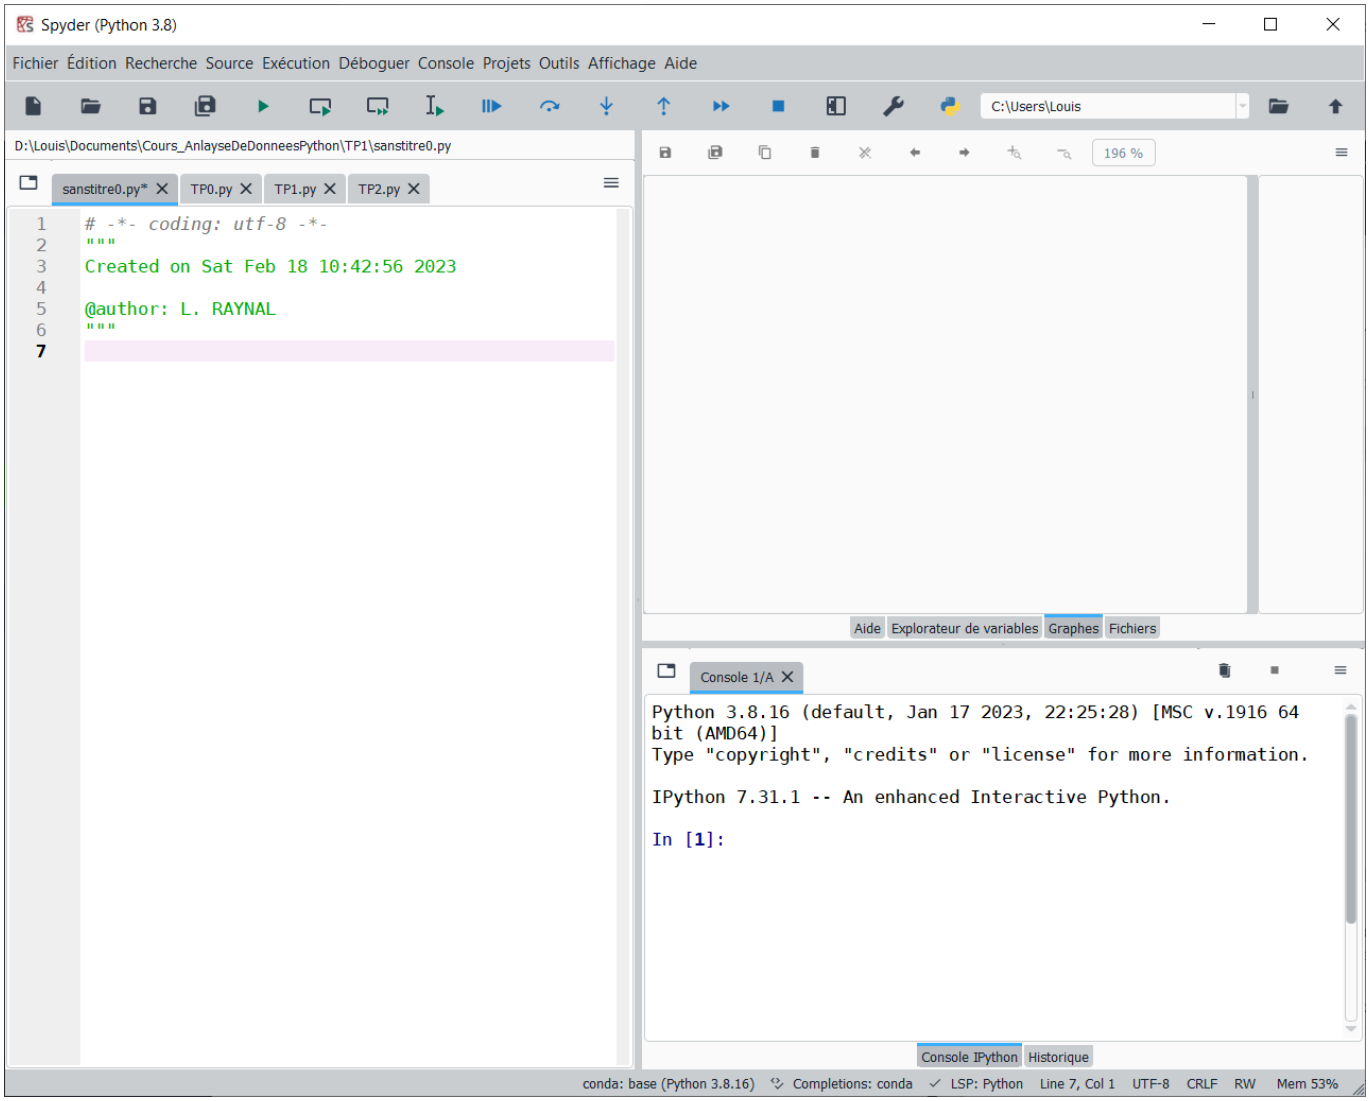

- La fenêtre de gauche est l'espace où vous rédigerez vos commandes en Python. Le nom du script est indiqué en haut à gauche de cette fenêtre (probablement `temp.py` ou `sanstitre.py`). Une `*` à côté de ce nom indique que ce fichier n'a pas été sauvegardé dans sa version la plus récente. Vous pourrez exécuter vos codes en sélectionnant les lignes souhaitées et en appuyant sur le symbole
- La fenêtre en bas à droite correspond à la `Console`. Les résultats de vos commandes exécutées (hors graphiques) y seront affichés. Cette fenêtre contient aussi un onglet `Historique` contenant l'historique des codes exécutés.
- La fenêtre en haut à droite contient de nombreux onglets, notamment `Explorateur de variables` (pour visualiser les variables définies) et `Graphes` (pour visualiser les graphiques tracés).

La version de base de Python étant rapidement limitée en termes de fonctionnalités, nous utiliserons des librairies complémentaires. Parmi elles vous rencontrerez :

- `numpy` – permet de travailler avec des vecteurs et matrices ;
- `pandas` – ajoute des structures adaptées pour l'analyse statistique et la manipulation de données ;
- `scipy` – contient de nombreux outils statistiques et lois de probabilité élémentaires ;
- `matplotlib` – la librairie standard pour la visualisation de données ;
- `seaborn` – une librairie plus évoluée que `matplotlib` pour la visualisation de données.

**Pratique**

> Ouvrir un nouveau script Python : *Fichier > Nouveau fichier*.
> Sauvegarder ce fichier sur votre bureau avec le nom TP1.py.
> A la fin de chaque séance de TP, pensez à conserver vos scripts sur le moyen de stockage de votre choix (email, google drive, clé USB, ...).
>
> Rappel : Votre script Python est le fichier qui contiendra vos différentes commandes que vous pourrez exécuter. Veillez à commenter vos codes (symbole `#`) et à ordonner vos codes dans l'ordre logique d'exécution (de haut en bas).

## 2. Rappels sur les structures de base de Python

Nous allons ici revoir des structures de base de Python qu'il est essentiel de connaître pour l'analyse de données.

**Exercices**

> Dans la suite, exécuter chaque ligne de code afin de comprendre les structures de données présentées.

### 2.1. Les tuples

Un **tuple** est une collection d'objets, créé grâce à des `( )` ou bien la fonction `tuple`. Une fois défini, un tuple est **immutable**, c'est-à-dire qu'il ne peut pas être modifié après sa création.

Code 1 – Exemples de tuples

```
tuple_1 = (1, 'a', True)
tuple_1

tuple_1[2]

tuple_1[2] = 'b'  # Ne fonctionne pas car les tuples sont immutables

```

```
tuple_2 = tuple([1,2,3])
tuple_2

tuple_2[1]
```

On rappelle qu'en Python, les indices commencent à 0. Le $i$-ième élément d'un tuple porte donc l'indice $i-1$.

### 2.2. Les listes

Une **liste** est une collection d'objets, créée grâce à des `[ ]` ou bien la fonction `list`. Contrairement aux tuples, les listes sont **mutables**, c'est-à-dire qu'elles peuvent être modifiées après création.

Code 2 – Exemples de listes

```
liste_1 = ['abc', 'def', 'ghi']
liste_1[1]

liste_1[2] = 0

liste_2 = list(tuple_1)
liste_2
```

### 2.3. Les dictionnaires

Un **dictionnaire** est une collection de **clés-valeurs non ordonnées**. Chaque clé est associée à une valeur, qui est un objet Python. Ce sont les clés qui vont permettre l'accès aux valeurs du dictionnaire. Un dictionnaire est habituellement créé grâce à des `{ }` ou avec la fonction `dict`.

Code 3 – Exemples de dictionnaires

```
dico_1 = dict(a=1, b=2, info='des informations')
dico_1['a']

dico_2 = {'a':1, 'b':[1,2,3,4,5], 'c':"plus d'informations"}
# Remarque : Pour la dernière valeur on déclare la chaîne entre " " car elle contient un '

dico_2['b']

dico_2['b'] = 5
dico_2['b']

dico_2.keys()
dico_2.values()
```

Maintenant que vous avez créé quelques variables, allez inspecter l'onglet `Explorateur de variables`. Pour chaque variable vous retrouverez son nom, son type, sa taille et son contenu. Vous pouvez double-cliquer sur ces variables pour voir plus clairement le contenu de chacune.

# 3. Présentation de NumPy

`numpy` est une librairie Python qui facilite grandement le travail avec des nombres, et va nous permettre de créer des **vecteurs** et **matrices**.

L'import de la librairie se fait habituellement de la manière suivante (à placer au début de votre script, avec vos autres imports de librairies) :

```
import numpy as np
```

Notez que l'on utilisera `np` comme alias pour `numpy`.

## 3.1. Création d'arrays

Cette librairie permet de créer des vecteurs et matrices, que l'on appellera ***arrays***. Pour créer un vecteur ou une matrice, on peut utiliser la fonction `array` de `numpy`.

Code 4 – Création d'un vecteur

```
data_1 = [1.5,2,3.4,4,5,6,7,8]   # à partir d'une liste
array_1 = np.array(data_1)
array_1
```

Code 5 – Création d'une matrice

```
data_2 = [[1,2,3,4], [5,6,7,8]] # à partir d'une liste de listes
array_2 = np.array(data_2)
array_2
```

Un array a une **taille**, ainsi qu'un **type** automatiquement déterminé par ce qu'il contient. Les méthodes `shape` et `dtype` d'un array permettent d'accéder à ces deux informations pour cet array.

Code 6 – Dimensions et type d'un array

```
# Obtenir les dimensions de ces deux arrays
array_1.shape
array_2.shape

# Obtenir le type de ces deux arrays
array_1.dtype
array_2.dtype
```

**Remarque**

On rappelle que :

- une **fonction** est définie avec le mot clé `def`, et retourne les objets définis par le mot clé `return` ;
- une **méthode** est une fonction qui est associée à un objet Python.

Par exemple, `shape` est une méthode associée à un objet de type array, qui retourne les dimensions de cet array.

`numpy` possède de nombreuses autres fonctions pour créer des arrays, en voici quelques unes. Notez que pour certaines de ces fonctions, donner un tuple au lieu d'une valeur entière changera l'array créé.

Code 7 – Autres fonctions pour créer des arrays

```
np.zeros(5)
np.zeros((5,3))

np.ones(5)
np.ones((5,3))

np.eye(5)

np.arange(20)
```

Enfin, bien que le type d'un array soit défini automatiquement par son contenu, il est possible d'indiquer son type lors de sa création avec l'argument `dtype`.

Code 8 – Spécification du type d'un array

```
array_f = np.array([1,2,3], dtype=np.float64)  # nombre flottant à 64 bits
array_i = np.array([1,2,3], dtype=np.int32)    # nombre entier à 32 bits

array_f.dtype
array_i.dtype

array_f
array_i
```

### 3.2. Calculs sur des arrays

L'un des avantages des arrays introduits par `numpy` est la facilité avec laquelle nous pouvons effectuer des calculs et comparaisons entre/sur eux.

Code 9 – Opérations sur les arrays

```
# Calculs
array_2 + array_2
array_2 * array_2
array_2 + 42

# Comparaisons
array_1 > 5
array_1 == 2
array_1 != array_1
```

`numpy` contient de nombreuses fonctions ou méthodes applicables aux arrays, afin d'effectuer des calculs pour l'analyse de données. Par exemple la méthode `mean()` pour calculer la moyenne, ou bien `var()` pour calculer la variance. Nous reviendrons sur ce genre de méthodes lors du prochain TP.

### 3.3. Extraction de données d'arrays

Pour la suite, il est important de savoir extraire des éléments constituants des arrays : **selon des positions** et **selon des conditions**. La manière de faire varie selon qu'il s'agit d'un vecteur ou d'une matrice.

Pour un vecteur cela fonctionne de manière similaire à une liste. Voici des exemples à expérimenter.

Code 10 – Extractions sur des arrays en une dimension

```
# Création d'un vecteur contenant les entiers de 5 à 9
array1D = np.arange(5,10)
array1D

# Différentes manières d'extraire des données d'un vecteur
array1D[:]        # tous les indices
array1D[1]        # indice 1
array1D[1:3]      # indice 1 à 3 exclu
array1D[1:]       # tout à partir de l'indice 1
array1D[:4]       # tout avant l'indice 4 exclu
array1D[-1]       # dernier indice
array1D[-3:]      # tout à partir de l'avant avant dernier indice
array1D[[0,4,2]]  # via une liste d'indice

# Modifications
array1D[0:2] = 17
array1D
```

Pour une matrice cela se complexifie. La logique est que l'on peut spécifier entre `[ , ]` les indices des lignes puis des colonnes à extraire.

Code 11 – Extractions sur des arrays en deux dimensions

```
array2D = np.array([[1,2,3,4],[5,6,7,8],[9,10,11,12]])
array2D

# Extraction de lignes
array2D[1,:]      # équivalent à array2D[1]
array2D[[1,2],:]  # équivalent à array2D[[1,2]]
array2D[:2,:]     # équivalent à array2D[:2]
# Le : pour dire "toutes les colonnes" n'est pas obligatoire

# Extraction de colonnes
array2D[:,1]
array2D[:,[0,1]]
array2D[:,1:]
# Le : pour dire "toutes les lignes" est obligatoire

# Extraction de lignes et colonnes
array2D[1][2] # soit en deux temps
array2D[1,2] # soit d'un coup

# Attention !
array2D[[0,1],[0,3]]
```

```
# donne les éléments avec indices (0,0) et (1,3)
# et non, tous les éléments aux lignes d'indice 0 et 1,
# et colonnes d'indice 0 et 3
# Pour ce faire, vous pouvez utiliser la fonction np.ix_ de numpy
# de la manière suivante :
array2D[np.ix_([0,1],[0,3])]
```

Une extraction sur un array peut permettre de modifier ses éléments souhaités :

Code 12 – Modifications d'un array grâce à une extraction

```
array2D[[0,1],[0,3]] = 0
array2D
```

Des **comparaisons logiques** sur les éléments d'un array peuvent grandement faciliter le remplacement de certaines de ses valeurs.

Code 13 – Comparaisons logiques dans un array

```
array2D > 5                  # Identifie par True les valeurs > 5, False sinon
array2D[ array2D > 5 ] = -1  # On remplace ces valeurs > 5 par -1
array2D
```

Cela n'est qu'un aperçu des possibilités offertes par la librairie `numpy`, et nous découvrirons d'autres fonctionnalités dans les prochains TP.

### Exercices

1. Créer un array avec 6 lignes et 4 colonnes avec uniquement des 0.
2. Assigner à la troisième et cinquième ligne les valeurs 1, 2, 3, 4.
3. Assigner 10 à tous les éléments de cet array égaux à 0.
4. Assigner 1.5 à tous les éléments de cet array se trouvant à l'intersection des lignes 2 et 3, et des colonnes 1, 3 et 4. (Utiliser la fonction `np.ix_`, voir fin du Code 11)
5. Recréer votre array de départ en spécifiant `dtype=np.int32` et relancez vos codes des questions 2 à 4. Que constatez-vous ?

### Attention

Faites très attention lorsque vous voulez copier un array dans une nouvelle variable, puis modifier cette copie.
Exécuter le code ci-dessous :

Code 14 – La mauvaise copie

```
array_1 = np.array([1,2,3,4])
array_copie = array_1[0:2]
array_copie

array_copie[1] = 42
array_copie
array_1
```

Vous voyez que l'array initial a aussi été modifié.

**Il faut utiliser la méthode `copy()` lorsque vous faites une copie d'un array.**

Code 15 – La bonne copie

```
array_1 = np.array([1,2,3,4])
array_copie = array_1[0:2].copy()
array_copie

array_copie[1] = 42
array_copie
array_1
```

## 4. Présentation de Pandas et de ses DataFrames

`pandas` est une librairie qui contient des structures, ainsi que des outils de manipulation de données, qui faciliteront grandement les analyses en Python.

L'import de la librairie se fait habituellement de la manière suivante :

```
import pandas as pd
```

L'analyse de données se base sur l'analyse de **données structurées**, prenant le plus souvent la forme d'un **tableau**. Chaque colonne du tableau porte un nom désignant l'information stockée dans celle-ci, et chaque ligne désigne un individu.

Pour reproduire ce genre de structures, `pandas` introduit un objet appelé ***DataFrame***. Un DataFrame est une structure en deux dimensions, où chaque colonne porte un nom et est potentiellement de type différent (numérique, chaîne de caractères, booléen, ...), et chaque ligne correspond à un individu.

### 4.1. Création de DataFrames à partir de dictionnaires

Un DataFrame peut se construire de différentes manières via la fonction `DataFrame` de `pandas`. L'une des plus communes est l'utilisation d'un dictionnaire, où toutes ses valeurs seront des listes de tailles égales, et ses clés seront nos noms de colonnes.

Créons par exemple un DataFrame avec trois colonnes, une première nommée `Produit` avec des noms de céréales, une deuxième avec le nombre de `Calories` de chaque céréales, et une troisième avec la quantité de `Protéines`.

Code 16 – Création d'un DataFrame à partir d'un dictionnaire

```
produit = ['Corn Flakes','Crispix','Golden Grahams','Muesli Raisins','Smacks','Special K']
calories = [100,110,110,150,110,110]
proteines = [2,2,1,4,2,6]

data = {'Produit' : produit,
        'Calories' : calories,
        'Proteines' : proteines}
# Exécutez bien les trois lignes ci-dessus en une fois

```

```
df = pd.DataFrame(data)
df
```

### 4.2. Création de DataFrames à partir d'une liste de listes

Une deuxième manière pour créer un DataFrame consiste à créer une liste de listes. Il faudra par contre spécifier les noms de colonnes avec l'argument `columns` de `pd.DataFrame`.

Code 17 – Création d'un DataFrame à partir d'une liste de listes

```
data2 = [['Corn Flakes',100,2],
        ['Crispix',110,2],
        ['Golden Grahams',110,1],
        ['Muesli Raisins',150,4],
        ['Smacks',110,2],
        ['Special K',110,6]]

df2 = pd.DataFrame(data2, columns=['Produit','Calories','Proteines'])
df2
```

Le DataFrame créé est affiché ci-dessous. Il s'agit d'un jeu de données avec 6 individus (ici des céréales), et pour chacun nous avons comme informations le nom du produit, le nombre de calories et la teneur en protéines.

| | Produit | Calories | Proteines |
|---|---|---|---|
| 0 | Corn Flakes | 100 | 2 |
| 1 | Crispix | 110 | 2 |
| 2 | Golden Grahams | 110 | 1 |
| 3 | Muesli Raisins | 150 | 4 |
| 4 | Smacks | 110 | 2 |
| 5 | Special K | 110 | 6 |

On retrouve les **valeurs** du DataFrame. Remarquez qu'il contient bien 3 colonnes nommées `Produit`, `Calories` et `Proteines`, mais aussi que chaque ligne est numérotée, il s'agit du nom porté par chaque ligne. Un DataFrame possède donc des **noms de colonnes**, ainsi que des **noms de lignes**. Si ces noms ne sont pas spécifiés lors de la création du DataFrame ils seront des entiers commençant à 0.

Pour afficher les valeurs, les noms de colonnes et les noms de lignes d'un DataFrame, nous pouvons utiliser les méthodes `values`, `columns` et `index` de celui-ci. Chaque colonne possède aussi un type, récupérable via la méthode `dtypes`.

Code 18 – Accès aux valeurs / noms de colonnes / noms de lignes

```
df.values # remarquez de c'est un objet de type numpy array qui est retourné

df.columns

df.index

df.dtypes
```

Nous verrons qu'il est important de faire la différence entre noms de lignes/colonnes et indices de lignes/colonnes (c'est-à-dire leurs numéros). Commençons par renommer les colonnes, et surtout les lignes pour pouvoir faire cette distinction.

Code 19 – Renommer les colonnes et lignes

```
df.columns = ['Produit','Calories','Protéines']

df.index = ['un','deux','trois','quatre','cinq','six']

df # vérification
```

### 4.3. Extraction de données de DataFrames

Une fois qu'un DataFrame est construit, nous voudrons inspecter les informations qui s'y trouvent. Voici différentes manières de faire.

Nous pouvons utiliser ses méthodes `head` et `tail` pour afficher un certain nombre des premières et dernières lignes du DataFrame.

Code 20 – Extractions des premières et dernières lignes

```
df.head()

df.tail()
```

Je vous invite à spécifier un nombre entier entre les parenthèses pour avoir le nombre de lignes souhaité.

Nous pouvons extraire des colonnes ou lignes de différentes manières.
Voici quelques manières simplifiées de faire :

Code 21 – Extractions de colonnes et de lignes

```
# Extraction de colonnes (via leurs noms)
df.Calories
df['Calories']
df[['Produit','Calories']]

# Extraction de lignes (via leurs indices)
df[2:5]
df[:5]
df[3:]

# Extraction de colonnes et lignes
df.Produit[1:]
df['Calories'][:4]
df[['Produit','Calories']][2:5]
```

Il existe cependant deux méthodes spécifiques pour l'extraction de données d'un DataFrame : `iloc` et `loc`.

La méthode `iloc` est conçue pour **extraire des lignes et colonnes d'un DataFrame en se basant sur les indices des lignes et colonnes**. Cette manière de faire est similaire à des extractions sur des arrays `numpy`.

Code 22 – Extractions grâce à `iloc`

```
df.iloc[2:5, :]   # équivalent à df.iloc[2:5]
df.iloc[:, [0,2]]
df.iloc[2:5, [0,2]]
df.iloc[2:5, 2:]
df.iloc[[0,4], [0,2]]
```

Il ne faut pas confondre `iloc` basée sur les indices (d'où le `i`), avec la méthode `loc` qui permet d'**extraire des lignes et colonnes en se basant sur leurs noms**.

Code 23 – Extractions grâce à `loc`

```
df.loc[['deux','trois','un'],:]   # équivalent à df.loc[['deux','trois','un']]
df.loc[:,['Produit','Protéines']]
df.loc[['deux','trois','un'],['Produit','Protéines']]
```

## 4.4. Modification d'un DataFrame

Vous pouvez vous baser sur les extractions précédentes avec `iloc` ou `loc`, pour modifier le contenu d'un DataFrame.

Code 24 – Modification de valeurs d'un DataFrame

```
df.loc[:,'Calories'] = 110
df

df.Protéines == 2 # permet d'identifier dans la colonne Protéines, les éléments égaux à 2
df.loc[df.Protéines == 2,'Protéines'] = 1
df

df.iloc[2:,1] = 120
df
```

## 4.5. Quelques méthodes utiles

Voici quelques méthodes utiles d'ordonnancement et de classement d'un DataFrame.
A vous d'expérimenter !

Code 25 – Trier un DataFrame selon les noms de lignes ou de colonnes

```
df.sort_index(axis=0)

df.sort_index(axis=1)

df.sort_index(axis=0, ascending=False)
```

Code 26 – Trier un DataFrame selon ses valeurs

```
df.sort_values(by='Protéines')

df.sort_values(by=['Protéines','Produit'])
```

Code 27 – Rang dans le classement des valeurs

```
df.rank(method='min')
```

Enfin, il est bon de connaître les méthodes `unique`, `count` et `value_counts` d'un DataFrame. La première permet de récupérer les modalités/valeurs différentes d'une colonne du DataFrame. La deuxième permet de compter l'effectif total, alors que la troisième permet d'obtenir pour une (ou plusieurs) colonne(s), les effectifs en fonction de ses modalités.

Code 28 – Modalités et effectifs

```
df.Protéines.unique()

df.Protéines.count()

df.Protéines.value_counts()
```

### Exercices

Pour ces exercices, utiliser le DataFrame `df2` créé dans le Code 17 qui n'est pas censé avoir été modifié, contrairement à `df`.

1. Trier `df2` par ordre alphabétique inverse des noms de céréales.
2. Trier `df2` dans l'ordre décroissant du nombre de calories, et utiliser `head` pour récupérer la ligne du DataFrame avec le plus grand nombre de calories.
3. Afficher pour chaque valeur de la colonne `Calories`, l'effectif correspondant.
4. En utilisant la réponse à la question précédente et la méthode `count()`, afficher la distribution en fréquence de la colonne `Calories`.